

Proyecto 1 - Inteligencia Artificial

1nd Sebastián Chaves Zumbado
Ingeniería en Computación
Tecnológico de Costa Rica
Cartago, Costa Rica
sebas04@estudiantec.cr

2st Kelvin Núñez Barrantes
Ingeniería en Computación
Tecnológico de Costa Rica
San José, Costa Rica
kelvinnb@estudiantec.cr

3nd Kenny Vega Obando
Ingeniería en Computación
Tecnológico de Costa Rica
Cartago, Costa Rica
kennyveoba@estudiantec.cr

Abstract—Este trabajo se centra en la aplicación de técnicas de clasificación en dos conjuntos de datos diferentes, el objetivo del primero dataset fue lograr predecir la presencia de diabetes en individuos, por otra parte el segundo se utilizó para evaluar la calidad de vinos, clasificándolos como buenos o malos. Evaluamos el rendimiento en ambos casos de los modelos y los comparamos entre sí.

Index Terms—Predicción, dataset, datos, valores, rendimiento.

I. INTRODUCTION

En el presente documento se llevara a cabo un análisis de dos database: el primero contiene datos de pacientes con diabetes y el segundo presenta datos sobre la calidad del vino. El objetivo principal de este análisis es evaluar y comparar el rendimiento de los medelos de Regresión Logística, KNN y Redes Neuronales en cada conjunto de datos. Antes de aplicar los modelos de aprendizaje, se llevará a cabo un proceso de tratamiento de datos para preparar el análisis, esto incluirá la limpieza de datos, la codificación de variables categóricas, la normalización de características y la división de los datos en conjuntos de entrenamiento y prueba.

Este análisis busca ofrecer una evaluación detallada de cómo se desempeñan los diferentes modelos en cada conjunto de datos.

II. ANÁLISIS DEL CONJUNTO DE DATOS DIABETES

El conjunto de datos de diabetes utilizado tiene como objetivo predecir si un paciente tiene o no diabetes, basándose en un conjunto de mediciones realizadas al paciente. Antes de empezar a entrenar nuestros modelos con los datos, primero nos aseguramos que estos estuvieran en condiciones óptimas para el trabajo, primero validamos que no existieran valores nulos, esto con ayuda de la funcion ".isnull()" proveniente de python, el resultado se observa en Fig. 1 donde se muestra la ausencia valores nulos.

Fig. 1. Cantidad valores nulos - Primer dataset

Pregnancies	0
Glucose	0
BloodPressure	0
SkinThickness	0
Insulin	0
BMI	0
DiabetesPedigreeFunction	0
Age	0
Outcome	0

Posteriormente, en la Fig. 2, se calculó las estadísticas descriptivas para todas las características, lo que incluyó la media, la mediana, la desviación estándar, así como los valores mínimos y máximos de cada una de las columnas.

Fig. 2. Estadísticas de valores - Primer dataset

	Pregnancies	Glucose	BloodPressure	SkinThickness
count	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458
std	3.369578	31.972618	19.355807	15.952218
min	0.000000	0.000000	0.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000
75%	6.000000	140.250000	80.000000	32.000000
max	17.000000	199.000000	122.000000	99.000000

	Insulin	BMI	DiabetesPedigreeFunction	Age
count	768.000000	768.000000	768.000000	768.000000
mean	79.799479	31.992578	0.471876	33.240885
std	115.244002	7.884160	0.331329	11.760232
min	0.000000	0.000000	0.078000	21.000000
25%	0.000000	27.300000	0.243750	24.000000
50%	30.500000	32.000000	0.372500	29.000000
75%	127.250000	36.600000	0.626250	41.000000
max	846.000000	67.100000	2.420000	81.000000


Este proceso nos permitió identificar posibles valores atípicos o anomalías en los datos, gracias a esto identificamos valores de cero en ciertas columnas en las que era imposible esa medición y logramos concluir esto gracias al valor de "min" provenientes de la Fig. 2. Esto se nota en el caso de la presión arterial, BMI, Glucosa, insulina y en el grosor de la piel.

Un valor de cero en cualquiera de estas medidas sería indicativo de un problema grave de salud, como un colapso cardiovascular o circulatorio extremo, incluso una persona con diabetes tipo 1, donde hay una disminución significativa en la producción de insulina, siempre tiene algo de insulina presente, ya sea a través de la producción residual del páncreas o mediante la administración de insulina por inyección.

Estos valores solo serían posibles en una situación de emergencia médica extrema por lo que en su lugar lo tomamos como un indicativo de valores faltantes, así que para abordar esta situación, se imputaron los valores de cero utilizando la media condicional según la variable objetivo, es decir, si una persona con diabetes tenía un valor de cero en alguna de estas características mencionadas, se reemplazó ese valor por la media de las personas con diabetes para esa característica en particular. De manera similar para el caso contrario, para las

personas sin diabetes se utilizó la media de los valores correspondientes a aquellas sin la enfermedad, logrando una mejor distribución de los datos como se refleja en la comparación de la Fig.3.

Fig. 3. Comparación de la distribución de densidad antes y después de tratar los datos



En la Figura 3, algunos gráficos de la izquierda logran resaltar de una forma muy clara los diversos valores en cero presentes en los datos, mientras que los de la derecha reflejan como se ve afectada su distribución después de reemplazar

estos valores por el promedio correspondiente para cada característica. Esta comparación se realizó mediante gráficos de densidad, pues estos permiten resaltar los cambios en la distribución de una mejor manera. También notamos como uno de los cambios más notorios se observa en la característica 'SkinThickness', la cual experimenta una transformación significativa debido a la gran cantidad de valores en cero que originalmente poseía.

Posteriormente de manejar los valores cero y los valores faltantes, se recalculó el resumen estadístico para todas las características del conjunto de datos. En esta ocasión los resultados mostrados en Fig. 4 reflejan resultados más acordes a lo esperado y el cómo mejora la distribución de los datos.

Fig. 4. Estadísticas de valores imputados - Primer dataset

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin
count	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	121.697358	72.428141	29.247042	157.003527
std	3.369578	30.462008	12.106044	8.923908	88.860914
min	0.000000	44.000000	24.000000	7.000000	14.000000
25%	1.000000	99.750000	64.000000	25.000000	121.500000
50%	3.000000	117.000000	72.000000	28.000000	130.287879
75%	6.000000	141.000000	80.000000	33.000000	206.846154
max	17.000000	199.000000	122.000000	99.000000	846.000000

	BMI	DiabetesPedigreeFunction	Age
count	768.000000	768.000000	768.000000
mean	32.44642	0.471876	33.240885
std	6.87897	0.331329	11.760232
min	18.20000	0.078000	21.000000
25%	27.50000	0.243750	24.000000
50%	32.05000	0.372500	29.000000
75%	36.60000	0.626250	41.000000
max	67.10000	2.420000	81.000000

Table. I: Se calculó la matriz de correlación entre todas las características y se identificaron las correlaciones absolutas para cada característica con respecto a la variable objetivo.

Esta información puede resultar relevante para comprender las relaciones entre las características y su influencia en la predicción de la enfermedad.

Realizamos una evaluación de las características disponibles y se consideró la relación de cada una con el resultado, establecimos un criterio de selección basado en la correlación de cada característica con el resultado final de la prueba, se determinó que las características que mostraran una correlación mayor al 10% serían consideradas relevantes para la creación de los modelos, mientras que las que mostraban un valor inferior a ese porcentaje serían descartadas. Tras realizar el análisis, se encontró que todas las características cumplían con este criterio, ya que presentaban una correlación con el resultado superior al 10% como se ve en la Table I, por lo tanto, se decidió seleccionar todas las características disponibles para la creación de las muestras utilizadas en los diferentes algoritmos de clasificación.

Con este análisis, se estableció una base para la implementación de modelos de clasificación, y se espera que nos permita avanzar en la correcta detección de la diabetes con mayor precisión y eficacia, con estos cambios tenemos el objetivo de eliminar la mayor cantidad de ruido posible y permitir que los algoritmos de clasificación evaluaran todas

TABLE I
PORCENTAJES DE CORRELACIÓN CON LA ENFERMEDAD.

Característica	Porcentaje de Correlación
Glucose	49.60%
Insulin	41.09%
BMI	31.53%
SkinThickness	30.81%
Age	23.84%
Pregnancies	22.19%
BloodPressure	17.51%
DiabetesPedigreeFunction	17.38%

las variables potencialmente en relación con la presencia de diabetes en los pacientes.

III. ANÁLISIS DEL CONJUNTO DE DATOS - CALIDAD DEL VINO

El conjunto de datos sobre la calidad del vino tiene como objetivo evaluar y predecir la calidad del vino basándose en diversas características físico-químicas.

Antes de comenzar a entrenar nuestros modelos con los datos, es crucial asegurarnos de que estén en condiciones óptimas para el trabajo al igual que en el caso anterior. En primer lugar, verificamos la presencia de valores nulos utilizando la función .isnull(). El resultado se muestra en la Fig. 5, donde se observa la ausencia de dichos valores.

Fig. 5. Cantidad valores nulos - Segundo dataset

Cantidad de datos nulos	
fixed acidity	0
volatile acidity	0
citric acid	0
residual sugar	0
chlorides	0
free sulfur dioxide	0
total sulfur dioxide	0
density	0
pH	0
sulphates	0
alcohol	0
quality	0

Para el caso de las estadísticas descriptivas de las características presentes en la Fig. 6, nos encontramos que todos los datos parecen estar dentro de rangos aceptables y esperados para las características del vino. Las medias, medianas y desviaciones estándar proporcionan una idea general de la distribución de los datos, mientras que los valores mínimos y máximos nos dan una idea de la variabilidad de las características.

En general, no se observaron valores extremadamente atípicos o fuera de lo común, lo que sugiere que los datos están bien distribuidos y no presentan anomalías significativas. Esto nos da confianza en la calidad y fiabilidad del conjunto de datos para su uso en el análisis y la construcción de modelos predictivos de para la calidad del vino.

Fig. 6. Estadísticas de valores - Segundo dataset

	fixed acidity	volatile acidity	citric acid	residual sugar	\
count	1599.000000	1599.000000	1599.000000	1599.000000	
mean	8.319637	0.527821	0.270976	2.538806	
std	1.741096	0.179060	0.194801	1.409928	
min	4.600000	0.120000	0.000000	0.900000	
25%	7.100000	0.390000	0.090000	1.900000	
50%	7.900000	0.520000	0.260000	2.200000	
75%	9.200000	0.640000	0.420000	2.600000	
max	15.900000	1.580000	1.000000	15.500000	

	chlorides	free sulfur dioxide	total sulfur dioxide	density
count	1599.000000	1599.000000	1599.000000	1599.000000
mean	0.087467	15.874922	46.467792	0.996747
std	0.047065	10.460157	32.895324	0.001887
min	0.012000	1.000000	6.000000	0.990070
25%	0.070000	7.000000	22.000000	0.995600
50%	0.079000	14.000000	38.000000	0.996750
75%	0.090000	21.000000	62.000000	0.997835
max	0.611000	72.000000	289.000000	1.003690

	pH	sulphates	alcohol	quality
count	1599.000000	1599.000000	1599.000000	1599.000000
mean	3.311113	0.658149	10.422983	0.534709
std	0.154386	0.169507	1.065668	0.498950
min	2.740000	0.330000	8.400000	0.000000
25%	3.210000	0.550000	9.500000	0.000000
50%	3.310000	0.620000	10.200000	1.000000
75%	3.400000	0.730000	11.100000	1.000000
max	4.010000	2.000000	14.900000	1.000000

Tras la preparación inicial de los datos, calculamos la matriz de correlación entre todas las características y la calidad del vino. En la Tabla II, se presentan las correlaciones absolutas. Al igual que en el caso anterior, establecimos un umbral del 10% para la selección de características relevantes para la construcción de modelos predictivos. Las que mostraron una correlación con la calidad del vino superior al 10% fueron consideradas relevantes, mientras que aquellas con una correlación inferior a este umbral fueron descartadas. Este enfoque nos permite centrarnos en las características que tienen una mayor influencia en la calidad del vino, lo que nos ayudará a construir modelos más precisos y eficaces para predecir la calidad del vino.

TABLE II
PORCENTAJES DE CORRELACIÓN CON LA CALIDAD DEL VINO.


Característica	Porcentaje de Correlación
Alcohol	43.47%
Volatile acidity	32.14%
Total sulfur dioxide	23.19%
Sulphates	21.80%
Citric acid	15.91%
Density	15.91%
Chlorides	10.94%
Fixed acidity	09.50%
Free sulfur dioxide	06.17%
PH	00.32%
Residual sugar	00.21%

Gracias a esto logramos identificar y descartar las características que mostraron una correlación con la calidad del vino por debajo del umbral establecido. Esto incluyó características como la acidez fija, dióxido de azufre libre, pH y contenido de azúcar residual, cuyas correlaciones fueron del 9.5%, 6.18%, 0.32% y 0.22% respectivamente. Al descartar estas

características menos relevantes, pudimos simplificar nuestro conjunto de datos y centrarnos en aquellas características que tienen una influencia más significativa en la calidad del vino.

Además, es importante destacar que los datos presentaban una distribución muy equilibrada, con una proporción cercana al 50% para cada clase. Esta distribución balanceada nos brinda la oportunidad de desarrollar modelos predictivos robustos y evitar sesgos inherentes a conjuntos de datos desequilibrados. Esta observación se muestra en la Fig 7.

Fig. 7. Distribución de clases - Segundo dataset



IV. EVALUACIÓN DEL MODELO

Se quiere comprobar que un modelo más complejo va a resultar en un modelo con mejor capacidad de predecir.

Para la evaluación del modelo se va a realizar la tarea de predecir el target seleccionado de los datasets utilizados, y luego se analizarán basándose en las métricas accuracy, precision, recall y además de una matriz de confusión para visualizar donde el modelo predice de forma errónea.

Al hacer la división de los datasets entre el 80% training y 20% testing, se utilizó el `random_state = 42` para asegurar una igualdad en la experimentación.

Para el caso de la diabetes nos centraremos más en la métrica de recall, la razón principal por la que nos centramos esta métrica es por su importancia en el contexto que nos encontramos. El recall, también conocido como sensibilidad o tasa de verdaderos positivos, nos indica la capacidad del modelo para identificar correctamente los casos positivos de las personas con diabetes. Es fundamental maximizar el recall del modelo para garantizar que identifique la mayor cantidad posible de pacientes que realmente tienen la enfermedad. Es crucial esta métrica porque un falso negativo en el diagnóstico de la diabetes podría llevar a que un paciente con la enfermedad no reciba el tratamiento y el cuidado médico adecuado, lo que podría tener consecuencias graves para su salud.

Por lo tanto, al centrarnos en el recall, estamos priorizando la capacidad del modelo para detectar correctamente los casos

de diabetes, lo que nos permite identificar a los pacientes que necesitan intervención médica y tratamiento de manera temprana y precisa. Esto puede mejorar significativamente la atención médica y la gestión de la enfermedad, lo que puede tener un impacto positivo en la salud y el bienestar de los pacientes.

Para el caso del análisis de la calidad del vino, aunque el recall es una métrica importante, también consideramos otras métricas como la precisión y el accuracy, por lo que decidimos darle un enfoque más general. Esto se debe a que la calidad del vino es un concepto multifacético que puede ser evaluado desde diferentes perspectivas, para obtener una comprensión completa de su capacidad para realizar recomendaciones precisas y confiables.

V. KNN

Para la implementación del modelo de vecinos más cercanos (KNN), se utilizó la biblioteca Scikit-learn.

Se ajustó el modelo KNN a los datos de entrenamiento utilizando diferentes configuraciones, incluyendo la variación del número de vecinos y la ponderación de los mismos. Se probaron diferentes valores para el número de vecinos (3, 5, 7, 10) y diferentes opciones para el peso de los vecinos, como 'uniform' y 'distance', para evaluar su impacto en la precisión del modelo. Se realizaron dos pruebas distintas para cada conjunto de datos con las diferentes configuraciones ya mencionadas, una utilizando los datos escalados y otra utilizando los datos en su forma original, es decir, sin escalados, para el caso del conjunto de diabetes los mejores 8 resultados basados en el recall se muestran en la TABLE III.

TABLE III
TOP 8 MEJORES COMBINACIONES DE MODELOS KNN CON MAYOR
RECALL - PRIMER DATASET

Escalado	Vecinos	Accuracy	Peso	Precision	Recall
No	3	Distancia	0.8442	0.7719	0.8
No	3	Uniforme	0.8312	0.7458	0.8
No	10	Distancia	0.8571	0.8113	0.7818
No	7	Distancia	0.8506	0.8077	0.7636
No	5	Distancia	0.8506	0.8077	0.7636
No	7	Uniforme	0.8442	0.7925	0.7636
No	5	Uniforme	0.8377	0.7778	0.7636
Si	10	distance	0.8312	0.7636	0.7636

Se observa que las combinaciones de modelos con el mejor desempeño en términos de recall se obtuvieron con un número de vecinos igual a 3, tanto en el caso de los datos escalados como en los datos en su forma original. Esto sugiere que en este conjunto de datos específico, trabajar con los datos sin escalar tiende a producir mejores resultados en términos de identificación de casos positivos, ya que si comparamos las combinaciones de modelos con el mismo número de vecinos y tipo de peso, se observa que la escalación de datos no tuvo un impacto significativo en el rendimiento del modelo en términos de recall.

Para el segundo conjunto de datos, que corresponde a la clasificación de vinos, se observa que las combinaciones de

modelos con el mejor desempeño en términos de accuracy se obtuvieron con un número de vecinos igual a 7 y utilizando la ponderación 'distance'. Esto sugiere que en este conjunto de datos específico, trabajar con los datos escalados tiende a producir mejores resultados en la precisión de clasificación, ya que las combinaciones de modelos con datos escalados muestran una mayor accuracy en comparación con los modelos que utilizaron datos sin escalar como se puede observar en la TABLE IV, donde todos los mejores resultados fueron con los datos escalados.

TABLE IV
TOP 8 MEJORES COMBINACIONES DE MODELOS KNN POR ACCURACY - SEGUNDO DATASET

Escalado	Vecinos	Peso	Accuracy	Precision	Recall
Si	7	distance	0.8063	0.8031	0.8659
Si	5	distance	0.8031	0.8118	0.8436
Si	3	distance	0.7937	0.7927	0.8547
Si	10	distance	0.7906	0.7979	0.8380
Si	10	uniform	0.7531	0.7941	0.7542
Si	5	uniform	0.7500	0.7647	0.7989
Si	3	uniform	0.7438	0.7513	0.8101
Si	7	uniform	0.7312	0.7435	0.7933

VI. REGRESIÓN LOGÍSTICA

Para la implementación del modelo de Regresión Logística se utilizó la librería de Sklearn utilizando su función de LogisticRegression.

En el caso de este modelo, se utilizó el optimizador "adam", loss "binary crossentropy" y la función de activación "sigmoid".

Con respecto al número de epochs, se hicieron varias pruebas con 100, 200, 300 y 400 para ambos datasets. Se encontró que el modelo presentó mejores resultados al utilizar 200 epochs ya que al aumentar de epochs no hay cambio en los resultados.

TABLE V
RESULTADOS DEL DATASET DIABETES

Epochs	Dataset 1		
	Accuracy	Precision	Recall
100	0.78	0.69	0.69
200	0.8	0.74	0.67
300	0.8	0.74	0.67

TABLE VI
RESULTADOS DEL DATASET CALIDAD DE VINO

Epochs	Dataset 2		
	Accuracy	Precision	Recall
100	0.74	0.8	0.72
200	0.75	0.8	0.73
300	0.75	0.8	0.73

Para el primer dataset, de acuerdo a la TABLE V, después de correr el modelo con 200 epochs se nos presenta un **Accuracy** del 0.8, una **Precision** del 0.74 y **Recall** del 0.67.

En la TABLE VIII tenemos los resultados de segundo dataset, acá no se presenta mucho cambio a partir de los 200 epochs en donde nos da un **Accuracy** del 0.75, una **Precision** del 0.8 y **Recall** del 0.73.

VII. REDES NEURONALES

En este trabajo, se empleó el MLPClassifier de Scikit-learn, un modelo de perceptrón multicapa, para abordar los problemas de clasificación de ambos datasets. Cada dataset fue preprocesado adecuadamente, escalando las características numéricas para mejorar la convergencia del modelo de red neuronal.

El MLPClassifier de Scikit-learn fue el modelo de elección, dada su capacidad para aprender modelos no lineales a través de una o más capas ocultas. Los principales parámetros ajustados fueron:

- **learning_rate_init**: La tasa inicial de aprendizaje, probando valores de 0.1, 0.01, y 0.001.
- **max_iter**: El número máximo de iteraciones, establecido inicialmente en 200, ajustable según la convergencia del modelo.
- **hidden_layer_sizes**: Configurado en (100,), indicando una capa oculta con 100 neuronas.

Se experimentó con la modificación de otros parámetros como **solver**, **early_stopping** y **learning_rate**, pero no se observaron grandes mejoras en los resultados. En las Tablas VII y VIII se muestran las variaciones en los resultados modificando el **learning_rate**.

TABLE VII
RESULTADOS DEL DATASET DIABETES

learning_rate	Dataset 1 - 200 Iterations		
	Accuracy	Precision	Recall
0.1	0.82	0.73	0.82
0.01	0.80	0.70	0.76
0.001	0.82	0.73	0.82

Realizar un análisis para determinar la importancia de las características mostró que, para el dataset de diabetes, las mediciones de glucosa y BMI fueron las más determinantes. En el caso del vino, el alcohol y los sulfatos tuvieron el mayor peso en la clasificación de la calidad.

El modelo presentó mejores resultados utilizando un **learning_rate**: 'adaptativo', un **learning_rate_init** de 0.01 y 100 como **hidden_layer_sizes**. Como estándar durante el experimento junto con otros modelos se realizaron 200 iteraciones. Obteniendo resultados de un **Accuracy** de 0.83, una **Precision** de 0.75 y un **Recall** de 0.77 para el diagnóstico de la diabetes.

TABLE VIII
RESULTADOS DEL DATASET CALIDAD DE VINO

learning_rate	Dataset 2 - 200 Iterations		
	Accuracy	Precision	Recall
0.1	0.76	0.8	0.75
0.01	0.79	0.87	0.71
0.001	0.76	0.81	0.71

VIII. COMPARACIÓN DE MODELOS

Para realizar la comparación del modelo con el conjunto de datos de diabetes, según los datos comentados anteriormente, se utilizarán las métricas de Accuracy, Precision y Recall. En la TABLE IX se muestra los resultados obtenidos.

TABLE IX
COMPARATIVA DE DESEMPEÑO DE LOS MODELOS - PRIMER DATASET.

Modelo	Accuracy	Precision	Recall
Redes Neuronales	0.83	0.75	0.77
Regresión Logística	0.80	0.74	0.67
KNN	0.84	0.77	0.80

Podemos observar que en general, el modelo KNN para esta tarea es el que presentó mejores resultados a la hora de predecir si un paciente tiene o no diabetes, seguido muy de cerca por el modelo de redes neuronales.

Podemos observar que en general, el modelo KNN para esta tarea es el que presentó mejores resultados a la hora de predecir la calidad de un vino.

- **KNN:** Destacó por su alto recall, alcanzando un valor del 80%. Esto indica que es efectivo para identificar correctamente los casos positivos de diabetes en el conjunto de datos. Además, obtuvo una precisión y un accuracy del 77% y 84% respectivamente, lo que lo convierte en un modelo sólido para la detección de la enfermedad.
- **Regresión Logística:** Si bien presentó valores considerablemente altos en accuracy y precision, su recall fue inferior en comparación con KNN y redes neuronales, alcanzando un 67%. Esto sugiere que la regresión logística puede perder algunos casos positivos de diabetes, lo que podría tener implicaciones negativas en el tratamiento de los pacientes.
- **Redes Neuronales:** Mostró un buen balance entre accuracy, precision y recall. Su recall fue similar al de KNN, alcanzando un valor del 77%. Esto sugiere que las redes neuronales pueden ser una opción sólida para la predicción de la diabetes, ya que logran identificar correctamente los casos positivos sin sacrificar la precisión en general.

Para realizar la comparación del modelo con el conjunto de datos para determinar la calidad del vino, según los datos comentados anteriormente, se utilizarán las métricas de Accuracy, Precision y Recall. En la TABLE X se muestra los resultados obtenidos.

TABLE X
COMPARATIVA DE DESEMPEÑO DE LOS MODELOS - SEGUNDO DATASET.

Modelo	Accuracy	Precision	Recall
Redes Neuronales	0.8	0.70	0.76
Regresión Logística	0.75	0.80	0.73
KNN	0.8	0.8	0.87

Al observar los resultados de las métricas de Accuracy, Precision y Recall en la tabla X, vemos que el modelo KNN

obtuvo la mayor puntuación en todas las métricas, por lo que podemos decir que el modelo KNN es el más efectivo para predecir la calidad del vino en comparación con los otros dos modelos. el modelo KNN alcanzó un accuracy del 80%, una precisión del 80% y un recall del 87%. Estos valores sugieren que el modelo KNN es altamente preciso en sus predicciones y tiene una buena capacidad para identificar correctamente los casos de calidad de vino.

Por otro lado, aunque la regresión logística presentó una precisión relativamente alta del 80%, su recall fue más bajo en comparación con KNN, lo que sugiere que podría estar perdiendo algunos casos de alta calidad de vino en su predicción.

Por último, las redes neuronales también mostraron un buen rendimiento, con un accuracy del 80%, una precisión del 70% y un recall del 76%. Aunque no alcanzó los mismos niveles que KNN en términos de precisión y recall, sigue siendo una opción competitiva para la clasificación de la calidad del vino.

Según los resultados del segundo dataset, el modelo KNN se destaca como el más adecuado para predecir la calidad del vino, seguido por las redes neuronales y la regresión logística.

IX. CONCLUSIONES

Se concluye la importancia de hacer un buen tratamiento de datos antes de procesarlos por el modelo. Esto es debido a que el quitar nulos o rellenar valores faltantes hacen que, en la mayoría de casos, nuestro modelo prediga de mejor manera.

Es importante destacar que el proceso de la imputación de valores en 0s aplicado al conjunto de datos de diabetes, demostró ser de gran ayuda para mejorar significativamente las métricas de clasificación. Este enfoque permitió que los modelos capturaran mejor las relaciones entre las variables y generaran predicciones más precisas. Este impacto positivo se evidencia claramente en la TABLE XI, donde se observa una mejora significativa en la precisión, accuracy y recall, después de aplicar el proceso de imputación de valores en ceros.

TABLE XI
COMPARACIÓN DE MÉTRICAS DE CLASIFICACIÓN ANTES Y DESPUÉS DE LA IMPUTACIÓN DE VALORES EN CEROS

Modelo	Métrica	Con 0s	Sin 0s	Mejora
Redes	Accuracy	0.6883	0.7987	11.04%
	Precision	0.5614	0.7000	24.68%
	Recall	0.5818	0.7636	31.22%
Logístico	Accuracy	0.7500	0.8000	6.67%
	Precision	0.6500	0.7400	13.85%
	Recall	0.6700	0.6700	0.00%
KNN	Accuracy	0.6494	0.8312	28.00%
	Precision	0.5072	0.7458	47.02%
	Recall	0.6364	0.8000	25.58%

Aunque la mejora del rendimiento no escala de manera perfectamente lineal debido a la interacción entre la calidad de los datos adicionales, la capacidad computacional y la estructura del modelo, en general, un mayor volumen de datos conduce a un aprendizaje más profundo y a una precisión mejorada. Este fenómeno destaca la importancia crítica de la cantidad y representatividad de los datos en el desarrollo de

soluciones de aprendizaje automático eficaces, particularmente en técnicas sofisticadas como las redes neuronales, que se benefician significativamente de conjuntos de datos extensos y bien curados.

Para finalizar, se rechaza la hipótesis, ya que el hecho que un modelo sea más complejo no necesariamente aumentará en la capacidad de predecir resultados.

REFERENCES

- [1] Data política. (2021, Abril). ¿Qué es la REGRESIÓN LOGÍSTICA?[YouTube]. [https://www.youtube.com/watch?v=qGpnYcw6T8ab_channel=Datapol](https://www.youtube.com/watch?v=qGpnYcw6T8ab_cw6T8ab_channel=Datapol)
- [2] Joaquín Amat. (2021, Mayo). Redes neuronales con Python [Online]. <https://cienciadedatos.net/documentos/py35-redes-neuronales-python.html>
- [3] Joaquín Amat. (2020, Noviembre). Regresión logística con Python [Online]. <https://cienciadedatos.net/documentos/py17-regresion-logistica-python.html>
- [4] Jolly, Eshin. (2022, Abril 8). Create a K-Nearest Neighbors Algorithm from Scratch in Python [Online]. <https://towardsdatascience.com/create-your-own-k-nearest-neighbors-algorithm-in-python-eb7093fc6339>
- [5] Víctor Romero. (2020, Octubre 3). Clasificador KNN — Machine Learning — Aprendizaje Automático — Python [Archivo de video]. YouTube. https://www.youtube.com/watch?v=qv0rb_A0f3Mab_channel=v

Criterios a evaluar		
Criterios	Puntuación máxima	Puntuación obtenida
Descarga y mostrar imágenes del dataset original	10	
Aplicar y analizar filtro Blur	15	
Aplicar y analizar filtro Sobel Edge Detection	15	
Aplicar y analizar filtro Canny Edge Detection	15	
Aplicar y analizar filtro seleccionado	15	
Estructura y claridad del informe	30	
Total		
Rúbrica Tarea NLP		
Criterios	Puntuación máxima	Puntuación obtenida
Definición de propósito de chatbot y respuestas	20	
Convertir las respuestas en embeddings y almacenarlo en un dataset de conocimiento	15	
Convertir la pregunta del usuario en embeddings	15	
Comparar los embeddings con similitud de coseno y mostrar la respuesta más acorde.	50	
Total		